lab3

Лабораторная работа 3

Задачи для лабораторной:

- работа с текстом;
- использование регулярных выражений для извлечения данных;
- переписывание существующего кода;
- ассиметричные распределения.

Исходные данные

Файл *forbes.htm* содержит список богатейших американцев по версии журнала Форбс. На его примере потренируемся в разборе html страниц.

Задание 1

1. Используйте команду readLines для загрузки файла в текстовый вектор html.

html <- readLines("https://raw.githubusercontent.com/SergeyMirvoda/MD-DA-2017/master/data/forbe
s.htm");</pre>

1. Сколько строк в файле?

length(html)

[1] 1991

2. Сколько символов в файле?

sum(nchar(html))

[1] 80380

2. Откройте файл в текстовом редакторе. Найдите строки, содержащие данные о Билле Гейтсе и Ларри Эллисоне и запомните размер их дохода.

1 Bill Gates



\$72 E

3 Larry Ellison



3. Напишите шаблон регулярного выражения и используйте функцию grep, чтобы извлечь размер дохода из данных в векторе *html*. Удостоверьтесь, что полученный вектор номеров строк содержит содержит ровно 100 записей и ссылается на номера строк в котрых действительно есть информация о доходе, а не просто первый попавшийся текст.

```
#$72 B
#worth.value <- grep('<td class="worth">\\$[\\d,]* B', html, value=TRUE, perl=TRUE)
#короче
worth.str <- grep('\\$[\\d,]* B', html, value=TRUE, perl=TRUE)
worth.str</pre>
```

```
[1] "\t\t$72 B"
##
  [2] "\t\t$58,5 B"
##
##
  [3] "\t\t$41 B"
  [4] "\t\t$36 B"
##
  [5] "\t\t$36 B"
##
##
  [6] "\t\t$35,4 B"
##
  [7] "\t\t$33,8 B"
##
  [8] "\t\t$33,5 B"
  [9] "\t\t$33,3 B"
##
  [10] "\t\t$31 B"
##
##
 [11] "\t\t$28,5 B"
##
 [12] "\t\t$27,2 B"
 [13] "\t\t$24,9 B"
##
##
 [14] "\t\t$24,4 B"
 [15] "\t\t$20,5 B"
##
 [16] "\t\t$20,5 B"
##
 [17] "\t\t$20,5 B"
##
 [18] "\t\t$20,3 B"
##
 [19] "\t\t$20 B"
##
##
 [20] "\t\t$19 B"
##
 [21] "\t\t$18 B"
 [22] "\t\t$17,8 B"
##
##
 [23] "\t\t$17,2 B"
 [24] "\t\t$16,3 B"
##
 [25] "\t\t$15,9 B"
##
##
 [26] "\t\t$15,8 B"
 [27] "\t\t$14 B"
##
##
 [28] "\t\t$14 B"
 [29] "\t\t$13,5 B"
##
 [30] "\t\t$13,4 B"
##
##
 [31] "\t\t$12,9 B"
 [32] "\t\t$12,5 B"
##
 [33] "\t\t$12,4 B"
##
 [34] "\t\t$12 B"
##
 [35] "\t\t$11,7 B"
##
##
 [36] "\t\t$11,4 B"
 [37] "\t\t$11,4 B"
##
 [38] "\t\t$10,3 B"
##
 [39] "\t\t$10,2 B"
##
##
 [40] "\t\t$10 B"
##
 [41] "\t\t$10 B"
##
 [42] "\t\t$9,8 B"
 [43] "\t\t$9,4 B"
##
##
 [44] "\t\t$9,3 B"
##
 [45] "\t\t$9 B"
 [46] "\t\t$8,9 B"
##
 [47] "\t\t$8,5 B"
##
##
 [48] "\t\t$8,5 B"
 [49] "\t\t$8,3 B"
##
 [50] "\t\t$8,3 B"
##
 [51] "\t\t$8,3 B"
##
 [52] "\t\t$8,2 B"
##
 [53] "\t\t$7,9 B"
```

```
[54] "\t\t$7,7 B"
##
##
 [55] "\t\t$7,7 B"
##
 [56] "\t\t$7,6 B"
##
 [57] "\t\t$7,5 B"
 [58] "\t\t$7,2 B"
##
##
 [59] "\t\t$6,9 B"
##
 [60] "\t\t$6,8 B"
##
 [61] "\t\t$6,7 B"
 [62] "\t\t$6,7 B"
##
 [63] "\t\t$6,7 B"
##
 [64] "\t\t$6,7 B"
##
 [65] "\t\t$6,4 B"
##
##
 [66] "\t\t$6,4 B"
 [67] "\t\t$6,4 B"
##
##
 [68] "\t\t$6 B"
 [69] "\t\t$6 B"
##
 [70] "\t\t$5,9 B"
##
 [71] "\t\t$5,8 B"
##
 [72] "\t\t$5,8 B"
##
 [73] "\t\t$5,7 B"
##
##
 [74] "\t\t$5,6 B"
 [75] "\t\t$5,6 B"
##
##
 [76] "\t\t$5,6 B"
##
 [77] "\t\t$5,5 B"
 [78] "\t\t$5,5 B"
##
 [79] "\t\t$5,5 B"
##
 [80] "\t\t$5,5 B"
##
##
 [81] "\t\t$5,5 B"
 [82] "\t\t$5,5 B"
##
 [83] "\t\t$5,5 B"
##
 [84] "\t\t$5,3 B"
##
##
 [85] "\t\t$5,2 B"
##
 [86] "\t\t$5,2 B"
 [87] "\t\t$5,2 B"
##
 [88] "\t\t$5,1 B"
##
 [89] "\t\t$5,1 B"
##
 [90] "\t\t$5 B"
##
##
 [91] "\t\t$5 B"
 [92] "\t\t$5 B"
##
 [93] "\t\t$4,9 B"
##
 [94] "\t\t$4,8 B"
##
 [95] "\t\t$4,7 B"
##
##
 [96] "\t\t$4,7 B"
 [97] "\t\t$4,7 B"
##
 [98] "\t\t$4,6 B"
##
 [99] "\t\t$4,6 B"
## [100] "\t\t$4,6 B"
```

```
worth.num <- grep('\\$[\\d,]* B', html, perl=TRUE)
worth.num</pre>
```

```
##
         547 557 567
                        577
                             587 597
                                       607
                                                 627
                                                                         677
    [1]
                                            617
                                                      637
                                                          647
                                                               657
                                                                    667
         687 697
                   707
                        717 727
                                  737
                                            757
                                                 767
                                                      777
                                                               797
                                                                         817
##
   [15]
                                       747
                                                          787
                                                                    807
##
   [29]
         827
              837 847
                        857 867
                                  877
                                       887
                                            897
                                                907
                                                     917
                                                          927
                                                               937
                                                                    947
                                                                         957
         967 977 987
                       997 1007 1017 1027 1037 1047 1057 1067 1077 1087 1097
##
   [43]
##
   [57] 1107 1117 1127 1137 1147 1157 1167 1177 1187 1197 1207 1217 1227 1237
##
   [71] 1247 1257 1267 1277 1287 1297 1307 1317 1327 1337 1347 1357 1367 1377
   [85] 1387 1397 1407 1417 1427 1437 1447 1457 1467 1477 1487 1497 1507 1517
##
   [99] 1527 1537
##
```

length(worth.str)

[1] 100

length(worth.num)

[1] 100

html[worth.num]

```
[1] "\t\t$72 B"
##
  [2] "\t\t$58,5 B"
##
##
  [3] "\t\t$41 B"
  [4] "\t\t$36 B"
##
  [5] "\t\t$36 B"
##
##
  [6] "\t\t$35,4 B"
##
  [7] "\t\t$33,8 B"
##
  [8] "\t\t$33,5 B"
  [9] "\t\t$33,3 B"
##
  [10] "\t\t$31 B"
##
##
 [11] "\t\t$28,5 B"
##
 [12] "\t\t$27,2 B"
 [13] "\t\t$24,9 B"
##
##
 [14] "\t\t$24,4 B"
 [15] "\t\t$20,5 B"
##
 [16] "\t\t$20,5 B"
##
 [17] "\t\t$20,5 B"
##
 [18] "\t\t$20,3 B"
##
 [19] "\t\t$20 B"
##
##
 [20] "\t\t$19 B"
##
 [21] "\t\t$18 B"
 [22] "\t\t$17,8 B"
##
##
 [23] "\t\t$17,2 B"
 [24] "\t\t$16,3 B"
##
 [25] "\t\t$15,9 B"
##
##
 [26] "\t\t$15,8 B"
 [27] "\t\t$14 B"
##
##
 [28] "\t\t$14 B"
 [29] "\t\t$13,5 B"
##
 [30] "\t\t$13,4 B"
##
##
 [31] "\t\t$12,9 B"
 [32] "\t\t$12,5 B"
##
 [33] "\t\t$12,4 B"
##
 [34] "\t\t$12 B"
##
 [35] "\t\t$11,7 B"
##
##
 [36] "\t\t$11,4 B"
 [37] "\t\t$11,4 B"
##
 [38] "\t\t$10,3 B"
##
 [39] "\t\t$10,2 B"
##
##
 [40] "\t\t$10 B"
##
 [41] "\t\t$10 B"
##
 [42] "\t\t$9,8 B"
 [43] "\t\t$9,4 B"
##
##
 [44] "\t\t$9,3 B"
##
 [45] "\t\t$9 B"
 [46] "\t\t$8,9 B"
##
 [47] "\t\t$8,5 B"
##
##
 [48] "\t\t$8,5 B"
 [49] "\t\t$8,3 B"
##
 [50] "\t\t$8,3 B"
##
 [51] "\t\t$8,3 B"
##
 [52] "\t\t$8,2 B"
##
 [53] "\t\t$7,9 B"
```

```
##
 [54] "\t\t$7,7 B"
 [55] "\t\t$7,7 B"
##
 [56] "\t\t$7,6 B"
##
 [57] "\t\t$7,5 B"
##
 [58] "\t\t$7,2 B"
##
##
 [59] "\t\t$6,9 B"
 [60] "\t\t$6,8 B"
##
##
 [61] "\t\t$6,7 B"
 [62] "\t\t$6,7 B"
##
 [63] "\t\t$6,7 B"
##
 [64] "\t\t$6,7 B"
##
 [65] "\t\t$6,4 B"
##
##
 [66] "\t\t$6,4 B"
 [67] "\t\t$6,4 B"
##
##
 [68] "\t\t$6 B"
##
 [69] "\t\t$6 B"
 [70] "\t\t$5,9 B"
##
 [71] "\t\t$5,8 B"
##
##
 [72] "\t\t$5,8 B"
 [73] "\t\t$5,7 B"
##
 [74] "\t\t$5,6 B"
##
 [75] "\t\t$5,6 B"
##
##
 [76] "\t\t$5,6 B"
 [77] "\t\t$5,5 B"
##
 [78] "\t\t$5,5 B"
##
 [79] "\t\t$5,5 B"
##
 [80] "\t\t$5,5 B"
##
##
 [81] "\t\t$5,5 B"
 [82] "\t\t$5,5 B"
##
##
 [83] "\t\t$5,5 B"
 [84] "\t\t$5,3 B"
##
 [85] "\t\t$5,2 B"
##
##
 [86] "\t\t$5,2 B"
 [87] "\t\t$5,2 B"
##
 [88] "\t\t$5,1 B"
##
 [89] "\t\t$5,1 B"
##
 [90] "\t\t$5 B"
##
##
 [91] "\t\t$5 B"
 [92] "\t\t$5 B"
##
 [93] "\t\t$4,9 B"
##
##
 [94] "\t\t$4,8 B"
 [95] "\t\t$4,7 B"
##
##
 [96] "\t\t$4,7 B"
 [97] "\t\t$4,7 B"
##
 [98] "\t\t$4,6 B"
##
 [99] "\t\t$4,6 B"
##
## [100] "\t\t$4,6 B"
```

- 4. Напишите код, использовав регулярное выражение из п. 3, и функции regexp и regmatches, чтобы извлечь все данные о доходе. Проверьте следующее:
- 5. Должно быть ровно сто значений.

```
worth.value <- regmatches(html, regexpr("\\$[\\d,]* B", html, perl = TRUE))
worth.value</pre>
```

```
[1] "$72 B"
                  "$58,5 B" "$41 B"
                                      "$36 B"
                                                "$36 B"
                                                          "$35,4 B" "$33,8 B"
##
    [8] "$33,5 B" "$33,3 B" "$31 B"
                                      "$28,5 B" "$27,2 B" "$24,9 B" "$24,4 B"
##
    [15] "$20,5 B" "$20,5 B" "$20,5 B" "$20,3 B" "$20 B"
                                                          "$19 B"
##
                                                                   "$18 B"
   [22] "$17,8 B" "$17,2 B" "$16,3 B" "$15,9 B" "$15,8 B" "$14 B"
                                                                   "$14 B"
##
    [29] "$13,5 B" "$13,4 B" "$12,9 B" "$12,5 B" "$12,4 B" "$12 B"
                                                                   "$11,7 B"
##
   [36] "$11,4 B" "$11,4 B" "$10,3 B" "$10,2 B" "$10 B"
                                                                   "$9,8 B"
##
                                                          "$10 B"
   [43] "$9,4 B" "$9,3 B"
                            "$9 B"
                                      "$8,9 B"
                                                "$8,5 B"
                                                         "$8,5 B"
                                                                   "$8,3 B"
##
   [50] "$8,3 B" "$8,3 B"
                            "$8,2 B"
                                      "$7,9 B"
                                                "$7,7 B" "$7,7 B"
                                                                   "$7,6 B"
##
   [57] "$7,5 B" "$7,2 B" "$6,9 B" "$6,8 B"
##
                                               "$6,7 B" "$6,7 B" "$6,7 B"
                            "$6,4 B" "$6,4 B"
                                               "$6 B"
   [64] "$6,7 B" "$6,4 B"
                                                         "$6 B"
                                                                   "$5,9 B"
##
##
   [71] "$5,8 B" "$5,8 B"
                            "$5,7 B" "$5,6 B"
                                               "$5,6 B" "$5,6 B"
                                                                   "$5,5 B"
                            "$5,5 B" "$5,5 B"
                                               "$5,5 B" "$5,5 B"
##
   [78] "$5,5 B"
                 "$5,5 B"
                                                                   "$5,3 B"
   [85] "$5,2 B" "$5,2 B" "$5,2 B" "$5,1 B" "$5,1 B" "$5 B"
                                                                   "$5 B"
##
   [92] "$5 B"
                  "$4,9 B"
##
                            "$4,8 B" "$4,7 B"
                                                "$4,7 B"
                                                         "$4,7 B"
                                                                   "$4,6 B"
   [99] "$4,6 B" "$4,6 B"
##
```

```
length(worth.value)
```

```
## [1] 100
```

2. Самый большой доход должен быть доход Билла Гейтса

```
#вычищаем мусор
worth.value <- gsub(" B","",worth.value)
worth.value <- gsub("\\$","",worth.value)
worth.value <- gsub(",",".",worth.value)
worth.value <- as.numeric(worth.value)
max(worth.value)
```

```
## [1] 72
```

3. Такой доход должен быть в списке один раз.

```
length(worth.value[worth.value == max(worth.value)])
```

```
## [1] 1
```

4. В всписке должна быть цифра, которую мы запомнили для Ларри Эллисона.

```
worth.value[3]
```

```
## [1] 41
```

5. Должно быть как минимум два значения, встречающихся несколько раз

sort(worth.value[duplicated(worth.value)]) #wtf 36

```
## [1] 4.6 4.6 4.7 4.7 5.0 5.0 5.1 5.2 5.2 5.5 5.5 5.5 5.5 5.5 ## [15] 5.5 5.6 5.6 5.8 6.0 6.4 6.4 6.7 6.7 6.7 7.7 8.3 8.3 8.5 ## [29] 10.0 11.4 14.0 20.5 20.5 36.0
```

Задание 2

5. В данных доход представлен в формате **"\$42 В"**, что означает **42 × 10^9**. Преобразуйте этот формат в числовой и сохраните в вектор *worths*. Удостоверьтесь в следующем:

```
worths <- worth.value * 10^9;
worths
```

```
##
     [1] 7.20e+10 5.85e+10 4.10e+10 3.60e+10 3.60e+10 3.54e+10 3.38e+10
##
    [8] 3.35e+10 3.33e+10 3.10e+10 2.85e+10 2.72e+10 2.49e+10 2.44e+10
##
   [15] 2.05e+10 2.05e+10 2.05e+10 2.03e+10 2.00e+10 1.90e+10 1.80e+10
   [22] 1.78e+10 1.72e+10 1.63e+10 1.59e+10 1.58e+10 1.40e+10 1.40e+10
##
   [29] 1.35e+10 1.34e+10 1.29e+10 1.25e+10 1.24e+10 1.20e+10 1.17e+10
##
   [36] 1.14e+10 1.14e+10 1.03e+10 1.02e+10 1.00e+10 1.00e+10 9.80e+09
##
##
   [43] 9.40e+09 9.30e+09 9.00e+09 8.90e+09 8.50e+09 8.50e+09 8.30e+09
   [50] 8.30e+09 8.30e+09 8.20e+09 7.90e+09 7.70e+09 7.70e+09 7.60e+09
   [57] 7.50e+09 7.20e+09 6.90e+09 6.80e+09 6.70e+09 6.70e+09 6.70e+09
##
   [64] 6.70e+09 6.40e+09 6.40e+09 6.40e+09 6.00e+09 6.00e+09 5.90e+09
##
##
   [71] 5.80e+09 5.80e+09 5.70e+09 5.60e+09 5.60e+09 5.60e+09 5.50e+09
##
   [78] 5.50e+09 5.50e+09 5.50e+09 5.50e+09 5.50e+09 5.50e+09 5.30e+09
   [85] 5.20e+09 5.20e+09 5.20e+09 5.10e+09 5.10e+09 5.00e+09 5.00e+09
##
   [92] 5.00e+09 4.90e+09 4.80e+09 4.70e+09 4.70e+09 4.70e+09 4.60e+09
##
   [99] 4.60e+09 4.60e+09
```

1. worths является вектором и в нём сто занчений типа double.

```
is.vector(worths)

## [1] TRUE

is.double(worths)

## [1] TRUE

length(worths)

## [1] 100
```

2. Все элементы вектора worths больше 1 миллиарда.

```
length(worths[worths > 10^9])
## [1] 100
  3. Самое большое число это доход Билла Гейтса.
max(worths)
## [1] 7.2e+10
  6. Используйте вектор worths, чтобы выяснить следующее:
  7. Какова медиана ста этих записей?
median(worths)
## [1] 8.3e+09
  2. Средний доход?
mean(worths)
## [1] 1.293e+10
  3. Как много людей из этого списка имеют доход больше 5млрд., 10, 25?
length(worths[worths > 5*10^9])
## [1] 89
length(worths[worths > 10*10^9])
## [1] 39
length(worths[worths > 25*10^9])
## [1] 12
  4. Какой их общий доход?
sum(worths)
## [1] 1.293e+12
```

2. Какую долю от общего дохода, составляет пятёрка самых богатых.

sum(worths[1:5])/sum(worths) * 100 #%

[1] 18.83217

3. Какую долю от общего дохода, составляют 20 самых богатых.

sum(worths[1:20])/sum(worths) * 100 #%

[1] 49.21114

4. В данных федерального резерва США (https://www.federalreserve.gov/releases/z1/current/z1.pdf) найдите показатель дохода всех домохозяйств (Household net worth) в соответвующем году, какую долю общего дохода составляют 100 богатейших людей.

household.net.worth <- 78.536 * 10^9 household.net.worth

[1] 7.8536e+10

sum(worths)

[1] 1.293e+12

#что-то пошло не так sum(worths) / household.net.worth

[1] 16.46379

